

Trabalho Prático Final – Opção 2

Desenvolvimento de um Sistema Inteligente Baseado em LLM para Consulta e Análise de Documentos

Objetivo

Projetar, implementar e demonstrar uma aplicação baseada em Inteligência Artificial capaz de responder perguntas sobre um conjunto de documentos utilizando técnicas modernas de Engenharia de Software para IA.

Descrição

Cada equipe deverá desenvolver um sistema que permita a um usuário realizar consultas em linguagem natural sobre uma base documental específica (artigos, normas, manuais, documentos jurídicos, relatórios, regulamentos, documentação técnica etc.).

A solução deverá implementar um pipeline de IA contemplando:

1. Coleta e preparação dos documentos.
2. Geração de embeddings.
3. Armazenamento em banco vetorial.
4. Recuperação de contexto (RAG).
5. Integração com um LLM.
6. Interface para consulta.

Requisitos Mínimos

Dados

- Base com pelo menos 20 documentos.
- Documentos em PDF, TXT ou HTML.

Processamento

- Extração automática dos documentos.
- Segmentação (chunking) dos textos.
- Geração de embeddings.

Banco Vetorial

Utilizar uma das opções:

- ChromaDB
- PGVector
- FAISS
- Qdrant

Modelo de IA

Utilizar pelo menos um LLM:

- GPT
- Claude
- Gemini
- Llama
- Mistral
- Outro equivalente

Aplicação

A solução deverá permitir:

- Inserção de perguntas em linguagem natural.
- Recuperação de trechos relevantes.
- Geração de resposta baseada no contexto recuperado.
- Exibição das fontes utilizadas.

Engenharia de Software

O projeto deverá demonstrar:

- Organização do código em módulos.
- Uso de controle de versão (Git).
- Configuração por arquivo de ambiente.
- Tratamento básico de erros.
- Documentação do projeto.

Tecnologias Sugeridas

- Python
- LangChain ou LlamaIndex
- OpenAI / Gemini / Claude
- ChromaDB ou PGVector
- Streamlit ou Gradio
- Docker (opcional)

Entregáveis

1. Código-fonte

Repositório Git contendo todo o projeto.

2. Relatório Técnico (5 a 10 páginas)

O relatório deverá conter:

1. Descrição do contexto dos documentos;
2. Processo de preparação dos dados (quando aplicável);
3. Embeddings utilizados;

4. LLMs utilizados.

Este relatório deve estar no README.md da raiz do repositório

Bônus (+10% na nota)

Implementar uma ou mais funcionalidades avançadas:

- Avaliação automática de respostas.
- Busca híbrida (vetorial + lexical).
- Multiagentes.
- Histórico de conversas.
- Reprocessamento incremental de documentos.
- Deploy em nuvem.
- Monitoramento e observabilidade da aplicação.
- Uso de MCP (Model Context Protocol).

Formação das Equipes

- Equipes de até 3 alunos.
- Entrega única por equipe, com os nomes de todos os membros no Readme do repositório.

Prazo de entrega

20 de julho, na plataforma Sigaa.